



Capacidades, limitaciones y coste

Elegir modelo es elegir **qué puede hacer bien, qué no debe hacer** y **cuánto pagas** por ello.

1. Qué problemas resuelve cada tipo

Tipo	Resuelve bien	No es su trabajo principal
LLM de texto (Transformer)	Chat, resumen, código, razonamiento con contexto	Búsqueda en millones de docs sin índice
Embeddings	Similitud semántica, recuperación para RAG	Redactar respuestas largas
Multimodal	Imagen + pregunta, OCR integrado	Solo tablas numéricas masivas
CNN (visión)	Clasificar/detectar en imágenes	Conversación abierta
RNN (secuencias)	Series cortas, modelos legacy	Chat generalista actual

2. Casos donde un modelo NO es adecuado

Quieres hacer...	Error común	Mejor enfoque
Búsqueda en 100k documentos	Meter todo en el prompt del LLM	Embeddings + top-K + LLM
Clasificar fotos de producto	Solo prompt de texto	CNN / modelo de visión
Chat con datos siempre actualizados	Confiar en memoria del modelo	RAG, API, base de datos
Verdad matemática/legal crítica	Una sola respuesta sin revisar	Validación, fuentes, humano
Latencia < 200 ms en móvil	Tier "pro" enorme	Modelo flash + prompt corto
10 M de clasificaciones/día baratas	Mismo LLM caro en cada fila	Modelo pequeño, batch, reglas

Quieres hacer...	Error común	Mejor enfoque
Privacidad estricta sin contrato	API pública sin revisar política	On-prem, anonimización, legal

Regla: si la fila de "error común" te suena familiar, cambia de **familia** o de **arquitectura**, no solo de prompt.

3. Limitaciones transversales de todos los LLM

```
El modelo NO es una base de datos
El modelo NO garantiza verdad
El modelo NO lee tu mente (sin contexto)
Más contexto ≠ siempre mejor respuesta
```

Limitación	Qué hacer en tu sistema
Alucinaciones	RAG, citas, "no sé", validación
Ventana finita	Resumir, recortar, menos chunks
Coste por token	Filtrar contexto en Python
Variabilidad	Temperatura baja, tests, JSON schema

4. Coste de utilizar modelos avanzados

"Avanzado" suele significar: tier **pro**, contexto **largo**, **multimodal**, o **mucho volumen**.

De qué depende el coste (sin fórmulas raras)

$$\text{COSTE} \approx (\text{tokens entrada} + \text{tokens salida}) \times \text{precio del tier} \times \text{número de llamadas}$$

Palanca	Efecto
Tier flash vs pro	Pro suele ser más caro y lento , mejor en tareas duras
Prompt largo (RAG sin filtrar)	Dispara tokens de entrada
Respuestas verbosas	Dispara tokens de salida
Chat con historial completo	Cada turno reenvía todo el historial
Multimodal	Suele costar más que texto solo
Muchas llamadas en batch	El total mensual importa más que una demo

Ejemplo mental

Escenario	Modelo típico	Comentario de coste
Soporte chat, miles/día	flash	Mantener si calidad suficiente
Informe legal complejo, pocos/día	pro	Pocos calls → coste aceptable
Etiquetar 1 M filas	flash o ML clásico	Pro en 1 M calls → inviable
Foto + pregunta ocasional	multimodal	OK; en volumen, evaluar OCR+CNN+texto

5. Escenarios de producto

Soporte (chat)

- **Familia:** texto (Transformer).
- **Evitar:** pro en cada "hola"; contexto FAQ sin filtrar.

RAG documentación

- **Familia:** embeddings + texto.
- **Evitar:** solo LLM sin recuperación.

Clasificación imágenes

- **Arquitectura:** CNN / visión — no LLM de chat.

OCR multimodal

- **Familia:** multimodal (Transformer) u OCR + texto.

Batch nocturno

- **Criterio:** el tier **más barato** que pase tu umbral de calidad medido en U2.

6. Checklist antes de elegir

- ☐ ¿Qué familia encaja? (texto / embeddings / multimodal / visión)
- ☐ ¿Qué arquitectura es la referencia? (Transformer / CNN / ...)
- ☐ ¿Hay caso donde NO sirve? (tabla §2)
- ☐ ¿Volumen y latencia aceptables?
- ☐ ¿Tier flash basta? (probar antes de subir)
- ☐ ¿Cómo mido en U2? (mismas preguntas, varios modelos)

7. Errores comunes

Error	Problema
LLM para todo	Coste y calidad peores que el enfoque correcto

Error	Problema
Ignorar embeddings en búsqueda	“No encuentra” o prompt gigante
Pro porque suena mejor	Factura y latencia sin ganancia real
Benchmark ajeno (MMLU) como única prueba	No refleja tu FAQ ni tu dominio