



Introducción: trade-offs y evaluación de modelos

Ahora aprenderemos a **medir** criterios de calidad en lugar de confiar en impresiones.

Evaluar un modelo = mismo input, mismas condiciones, métricas comparables.

No elijas el modelo que brilla en un ejemplo; elige el que gana en tu matriz de evaluación con tus preguntas y tus límites de coste y latencia.

Objetivos de la unidad

Al terminar, deberías poder:


- Explicar trade-offs entre **calidad**, **latencia** y **coste**.
 - Leer `usage_metadata` y tiempo de respuesta en llamadas Gemini.
 - Diseñar un mini-benchmark con **3–5 preguntas fijas**.
 - Interpretar benchmarks públicos con **cautela** (no sustituyen tu caso de uso).
 - Rellenar una **matriz de evaluación** antes de elegir modelo en producción.
-

Qué significa “evaluar” en producción

En bootcamp / MVP	En producción
3–5 prompts manuales	Dataset de evaluación + regresiones
Latencia en tu portátil	p50 / p95 en tu región
Tokens de una llamada	Coste mensual agregado
“Me gusta más esta respuesta”	Rubric + revisión humana o tests automáticos

El espíritu es el mismo: **decisiones con datos**, no con un chat suelto.

Las tres dimensiones



No existe el triángulo perfecto. Existe el **equilibrio aceptable** para tu producto.