



Latencia, coste y precisión

Tres números (y una valoración cualitativa) dominan la mayoría de decisiones de modelo en APIs.

1. Precisión / calidad

Qué es: qué tan bien responde el modelo **en tu tarea**, no en un examen genérico.

Cómo medirlo:

- Mismas preguntas para todos los modelos.
- Rubric simple: 1–5 en claridad, corrección, tono, formato.
- Tests automáticos cuando la salida es estructurada (JSON válido, etiqueta en whitelist).

Cuidado: una respuesta más larga no es necesariamente mejor.

2. Latencia

Qué es: tiempo desde que envías la petición hasta que recibes la respuesta útil.

Métrica	Significado
Tiempo total	Lo que percibe el usuario en chat
TTFT (time to first token)	Importante en streaming
p95	El 5 % peor de peticiones — crítico en SLAs

Factores: tamaño del modelo, longitud del prompt, región, carga del proveedor, streaming vs no streaming.

```
import time

t0 = time.time()
response = client.models.generate_content(model=MODEL, contents=prompt)
elapsed_ms = int((time.time() - t0) * 1000)
```

En la demo compararás `elapsed_ms` entre modelos con el **mismo prompt**.

3. Coste computacional (vía tokens)

En APIs comerciales el coste suele derivarse de **tokens**:

Concepto	Impacto
Tokens de input	Contexto largo, RAG mal filtrado
Tokens de output	Respuestas verbosas, <code>max_output_tokens</code> alto
Llamadas por sesión	Chat con historial completo cada turno

```
um = response.usage_metadata
prompt_tokens = um.prompt_token_count
output_tokens = um.candidates_token_count
total_tokens = um.total_token_count
```

Coste aproximado = tokens × precio por millón (consulta la tarifa actual del proveedor).

4. Tabla de trade-offs (orientativa)

Prioridad producto	Suele ganar	Suele perder
Chat en tiempo real	Modelo flash, prompt corto	Matices en tareas muy difíciles
Análisis profundo offline	Tier pro, más contexto	Latencia y factura
Alto volumen batch	Modelo barato + pipeline	Último % de calidad
Salida JSON estricta	Temperatura baja + validación	Creatividad

5. Misma pregunta, distintos modelos

Patrón de evaluación justa:

```
PREGUNTAS_FIJAS = [q1, q2, q3, q4, q5]
MODELOS = [flash, otro_tier, ...]

para cada q en PREGUNTAS_FIJAS:
    para cada m en MODELOS:
        medir(latencia, tokens, respuesta)
        anotar calidad (humano o rubric)
```

Misma temperatura y mismos límites salvo que quieras estudiar explícitamente ese hiperparámetro.

6. Plantilla de matriz (para el notebook)

Pregunta	Modelo	ms	in	out	Calidad 1-5	Notas
q1	gemini-3-flash-preview					
q1	gemini-2.5-pro					

Copia esta tabla en tu cuaderno o en un documento de decisión.