



Robustez, métricas y benchmarks

“Robusto” aquí significa: **comportamiento estable** ante variación de inputs y condiciones — no solo una respuesta bonita en el demo.

1. Robustez en apps con LLM

Aspecto	Pregunta
Formato	¿Devuelve JSON válido cuando lo pides?
Dominio	¿Se sale del tema con preguntas límite?
Consistencia	¿Misma pregunta → misma categoría (con temp baja)?
Errores	¿Qué pasa con input vacío, muy largo o ambiguo?

La robustez del **sistema** (validación, reintentos, fallbacks) complementa la del modelo — ya trabajaste capas en Sprint 6.

2. Métricas útiles para cada tarea

Tarea	Métricas
Clasificación	Accuracy, F1 por clase, tasa de “OTRO”
QA con contexto	% respuestas con cita correcta, alucinaciones
Generación libre	Rubric humana, checklist
Código	Tests que pasan, lint
Chat	CSAT, escalado a humano, longitud media

En nuestro caso, empezamos con **rúbrica 1–5 + latencia + tokens**.

3. Benchmarks públicos (MMLU, HumanEval, etc.)

Los leaderboards miden tareas **estandarizadas**. Sirven para:

- Orientación grosso modo (tier pro vs flash).
- Detectar modelos obsoletos.

No sirven para sustituir evaluación en tu dominio:

- Tu FAQ no está en MMLU.
- Tu política de tono no está en el benchmark.
- Tu mezcla input/output de tokens es distinta.

Usa benchmarks como **contexto**, no como veredicto final.

4. Diseño de un mini-benchmark propio

1. **Elige 5–20 preguntas** representativas (no solo las fáciles).
2. Incluye **casos límite** (vacío, jerga, intento de injection).
3. **Congela** prompt plantilla y temperatura.
4. Ejecuta todos los modelos candidatos.
5. Registra métricas automáticas + revisión humana en muestra.
6. **Documenta** la decisión (aunque sea “nos quedamos con flash por $p_{95} < 2s$ ”).

5. Errores al evaluar

Error	Corrección
Cambiar el prompt entre modelos	Un solo template
Una sola pregunta “wow”	Conjunto fijo
Ignorar coste en producción	Proyectar tokens × volumen
Evaluar solo una vez	Repetir en otro día / región si es crítico