



Introducción: benchmarking con Python

Anteriormente vimos cómo comparar modelos de manera manual con un **criterio** y **comparación manual**. Aquí **automatizas** el pipeline:

```
dataset (preguntas) → runs por modelo → log (CSV) → informe
```

Objetivos

- Estructurar un evaluador mínimo con módulos (`config`, `cliente`, `benchmark`, `report`, `main`).
- Medir latencia y tokens de forma reproducible.
- Guardar resultados para comparar ejecuciones en el tiempo.
- Generar un informe Markdown legible para stakeholders técnicos.

Convención para nuestro proyecto

```
proyecto_evaluador/  
├─ config.py          # modelos, temperatura, rutas  
├─ gemini_auth.py     # .env + getpass  
├─ gemini_client.py   # llamada + métricas  
├─ benchmark.py       # bucle pregunta × modelo  
├─ report.py          # CSV + report.md  
├─ data/preguntas.json  
└─ main.py
```