

Bootcamp IA Engineering

Módulo 4 - RAG Engineering

Luis Ivan Umpire Alvarez

CHECK-IN

RECEPCIÓN



Check-in del Profesor

Luis Iván Umpire Alvarez

Estudios

- Ingeniero Electrónico
- Master en Data Science & Advanced Analytics
- Master en Sistemas
- MBA

Experiencia

- IA
- Negocios
- Desarrollo de Productos

Hobby



TU TURNO

Preséntate brevemente



¡Eres el siguiente!



CHECK-IN PERSONAL

- ¿Cuál es tu nombre?
- ¿Dónde trabajas / área?
- ¿Cuál es tu hobby favorito?

NUESTRO JOURNEY



Journey del Bootcamp

RAG

1



Módulo 1-
Python + IA
Generativa

2




Módulo 2 –
Prompt & context
engineering

3




Módulo 3 -
Arquitecturas y
Modelos de IA

4



Módulo 4 –
RAG Engineering.

5




Módulo 5 –
AI Agents
Engineering

➡ **PROYECTO**


Journey del Bootcamp

RAG



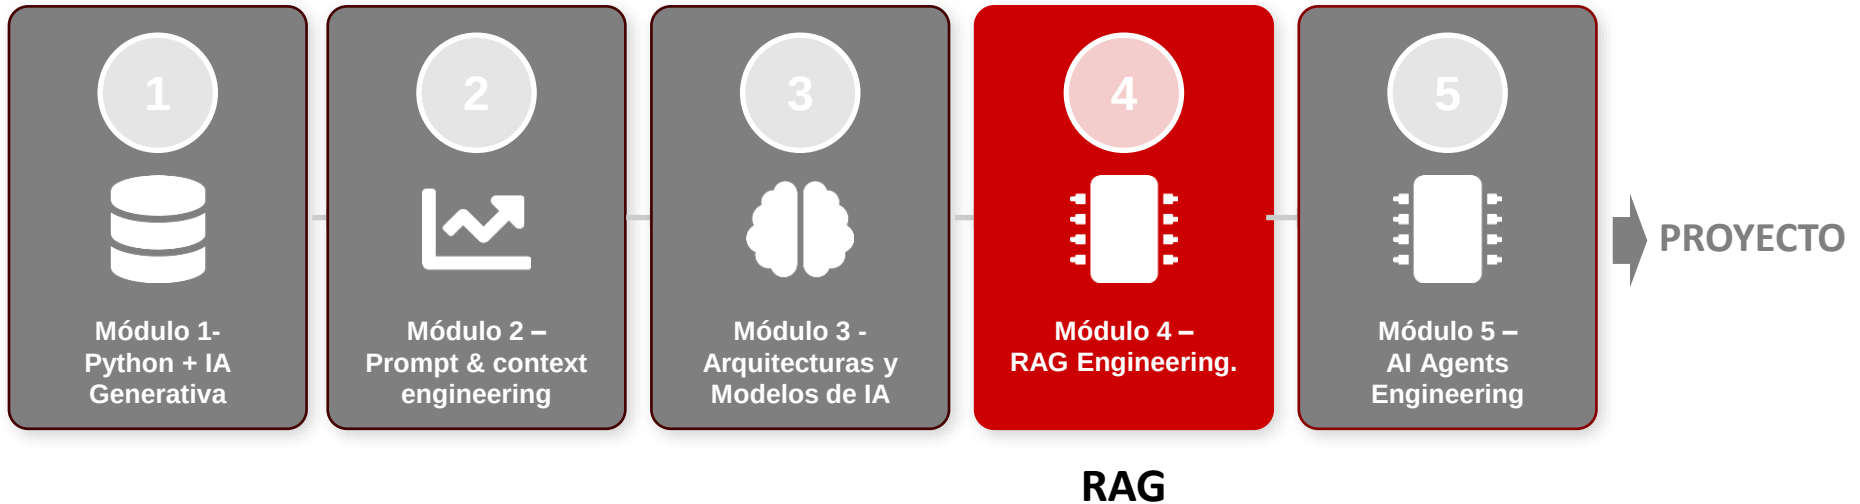
Journey del Bootcamp

RAG



Journey del Bootcamp

RAG



1. PREGUNTA A CHATGPT



TÚ



¿Cuál es la capital de España?

10:30 AM

CHATGPT



La capital de España es
Madrid.

10:30 AM ✓

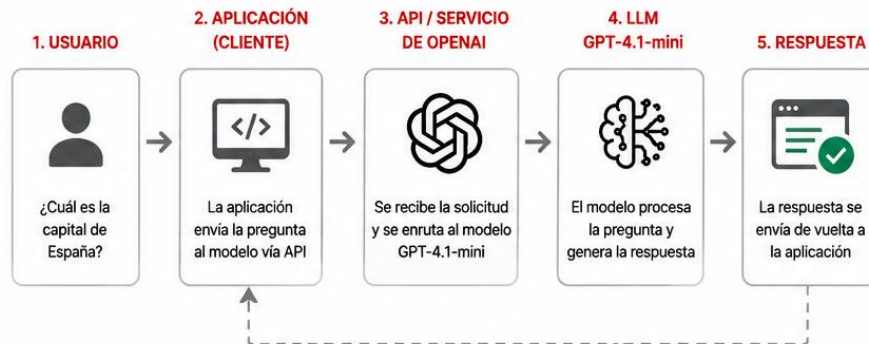


Estás usando ChatGPT (interfaz conversacional)

- Experiencia optimizada para conversar
- Historial de conversación
- Herramientas y funciones integradas

2. PREGUNTA ENVIÁNDOLA AL LLM GPT-4.1-mini

ARQUITECTURA DE ALTO NIVEL



RESPUESTA RECIBIDA POR LA APLICACIÓN

```
{
  "respuesta": "La capital de España es Madrid."
}
```



¿Qué está ocurriendo?

Tu aplicación envía la pregunta al modelo GPT-4.1-mini vía API. El modelo procesa la solicitud y devuelve la respuesta en formato texto (normalmente JSON), que tu aplicación puede usar.

¿Por qué necesitamos RAG?



CASOS

CASO 1

CHATBOT BANCARIO

Un banco quiere desarrollar un asistente para atender consultas sobre tarjetas de crédito.



¿Cuál es la tasa de interés de la tarjeta Platinum?

¿Cuánto pago si retiro efectivo?

¿Qué seguros incluye mi tarjeta?

¿Cómo bloqueo mi tarjeta si la pierdo?



PROBLEMA: El LLM no conoce la información interna del banco.
No existe contexto.

CASO 2

CAMPAÑA COMERCIAL

Movistar está haciendo una campaña de migración por WhatsApp.

Ofrece el último iPhone a un precio súper competitivo.



¿Puedo acceder si soy nuevo cliente?



¿La promoción termina este domingo?



¿Qué ocurre si cancelo antes de terminar las cuotas?



¿Puedo combinar esta promoción con otra?



iPhone 18 Pro

Antes: 1.599 €

Ahora: 999 €

36 cuotas | Clientes Premium



PROBLEMA: El LLM no tiene acceso a la información actualizada de la campaña ni a sus condiciones.

CASO 3

INSTITUTO / UNIVERSIDAD

Un instituto utiliza IA para responder dudas de los alumnos.



¿Cuál es el horario del curso de Python?




¿Cuándo vence la matrícula?



¿Qué requisitos tiene el Proyecto Final?



¿Quién es mi tutor?



Asistente Institucional

No tengo acceso al reglamento ni a la información interna de este instituto.



10:48

No puedo responder esa pregunta.



11:45



PROBLEMA: El LLM no conoce el reglamento, procesos ni datos internos del instituto.

CASO 4

IOT – SENSORES METEOROLÓGICOS

Tenemos miles de sensores que registran datos meteorológicos en tiempo real.



¿Qué temperatura registró el sensor 53 ayer a las 18:00?



¿Cuál fue la calidad del aire durante el fin de semana?



¿Hubo niveles de contaminación superiores a lo normal?



¿Cuánta lluvia acumuló la estación central el mes pasado?



Asistente de Datos

No tengo acceso a los datos de tus sensores en tiempo real.



11:45

No puedo responder esa pregunta.



11:45

...



PROBLEMA: El LLM nunca ha visto esos datos.
No existe contexto.

¿Qué tienen en común?

¿Qué tienen en común?



D E M O

AcademiaIA: **Campaña para impulsar la inscripción en su programa DS + IA**

Las personas que hacen click en la campaña de Instagram son llevadas a WhatsApp.
Nuestra solución, usando la API de WhatsApp, responde consultas sobre el programa en tiempo real.

AcademiaIA:

Campaña para impulsar la inscripción en su programa DS + IA



Instagram

Campaña de publicidad



AcademiaIA:

Campaña para impulsar la inscripción en su programa DS + IA



Instagram

Campaña de publicidad




El usuario hace click en el anuncio y envía mensaje



WhatsApp

Vía API Oficial




AcademiaIA:

Campaña para impulsar la inscripción en su programa DS + IA



El usuario hace click en el anuncio y envía mensaje



WhatsApp (API) envía el mensaje a nuestra aplicación




AcademiaIA:

Campaña para impulsar la inscripción en su programa DS + IA



El usuario hace click en el anuncio y envía mensaje



WhatsApp (API) envía el mensaje a nuestra aplicación



¿Qué puede responder nuestra solución?



Contenido del programa



Fecha de inicio y horarios



Precios y formas de pago



Requisitos y perfil de ingreso



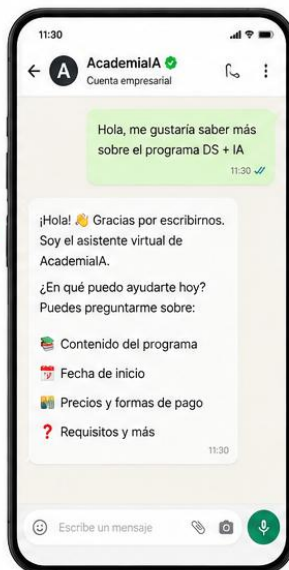
Modalidad, sede y más

AcademiaIA:


Campaña para impulsar la inscripción en su programa DS + IA



El usuario hace click en el anuncio y envía mensaje



WhatsApp (API) envía el mensaje a nuestra aplicación



¿Qué puede responder nuestra solución?



Contenido del programa



Fecha de inicio y horarios



Precios y formas de pago



Requisitos y perfil de ingreso



Modalidad, sede y más



Con RAG, nuestra solución usa la información oficial de AcademiaIA para dar respuestas precisas, actualizadas y alineadas con el negocio.

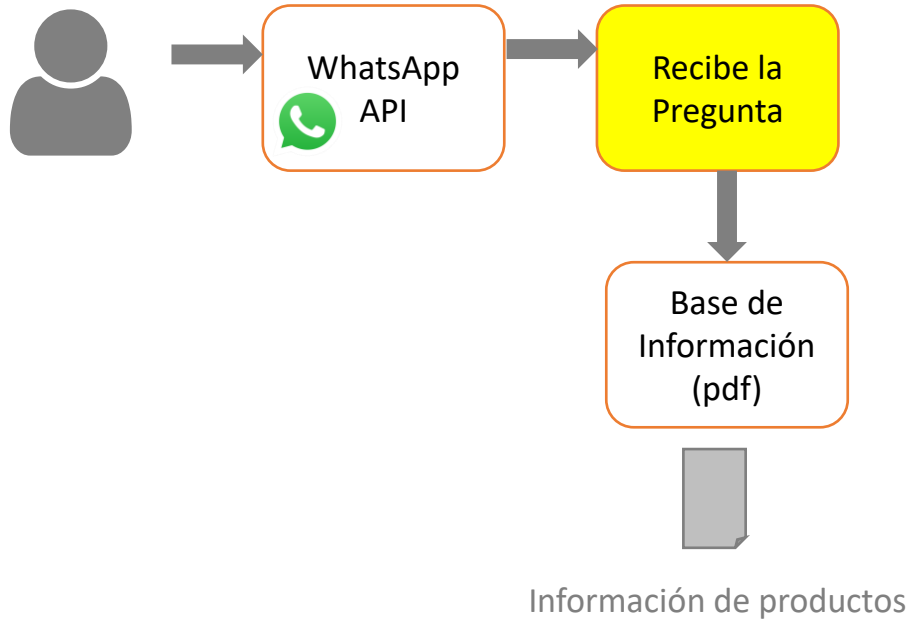
Ejemplo: Optimizar el proceso de ventas por WhatsApp




Ejemplo: Optimizar el proceso de ventas por WhatsApp




Ejemplo: Optimizar el proceso de ventas por WhatsApp




Ejemplo: Optimizar el proceso de ventas por WhatsApp




Ejemplo: Optimizar el proceso de ventas por WhatsApp




Ejemplo: Optimizar el proceso de ventas por WhatsApp



Ejemplo: Optimizar el proceso de ventas por WhatsApp



Ejemplo: Optimizar el proceso de ventas por WhatsApp



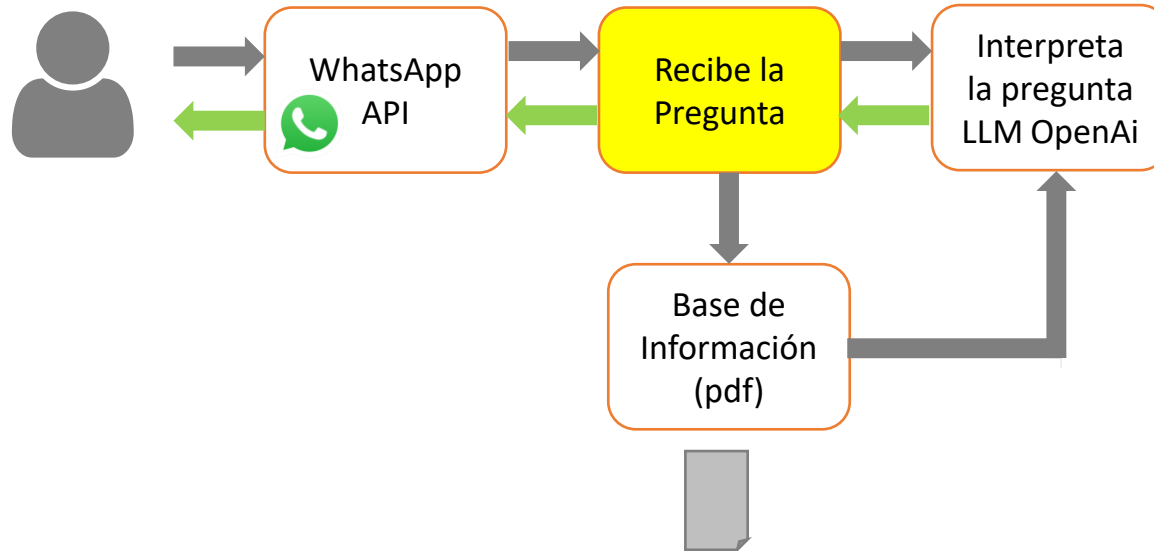
DEMO <https://laboratoriochatbot1-luisivanumpirealvarez.streamlit.app/>

¿Qué es RAG?

RAG significa **Retrieval-Augmented Generation**, un enfoque donde el modelo no responde solo con lo que sabe internamente, sino que **busca primero información relevante en una base externa (documentos, PDFs, base vectorial, etc.)**, y luego genera una respuesta usando ese contexto.

Término	Traducción literal	Significado práctico en RAG
Retrieval	Recuperación	El sistema busca información relevante (por ejemplo, en una base vectorial de embeddings).
Augmented	Aumentado / Ampliado	La generación no se basa solo en el conocimiento del modelo, sino que se "aumenta" con información externa .
Generation	Generación	El modelo genera la respuesta final usando tanto su conocimiento previo como el contexto recuperado.


Ejemplo: Optimizar el proceso de ventas por WhatsApp



Le estoy indicando al modelo que use mi Información como base de conocimiento.


Ejemplo: Chatbot con IA

¿Qué problema observan?




Ejemplo: Chatbot con IA

¿Qué problema observan?



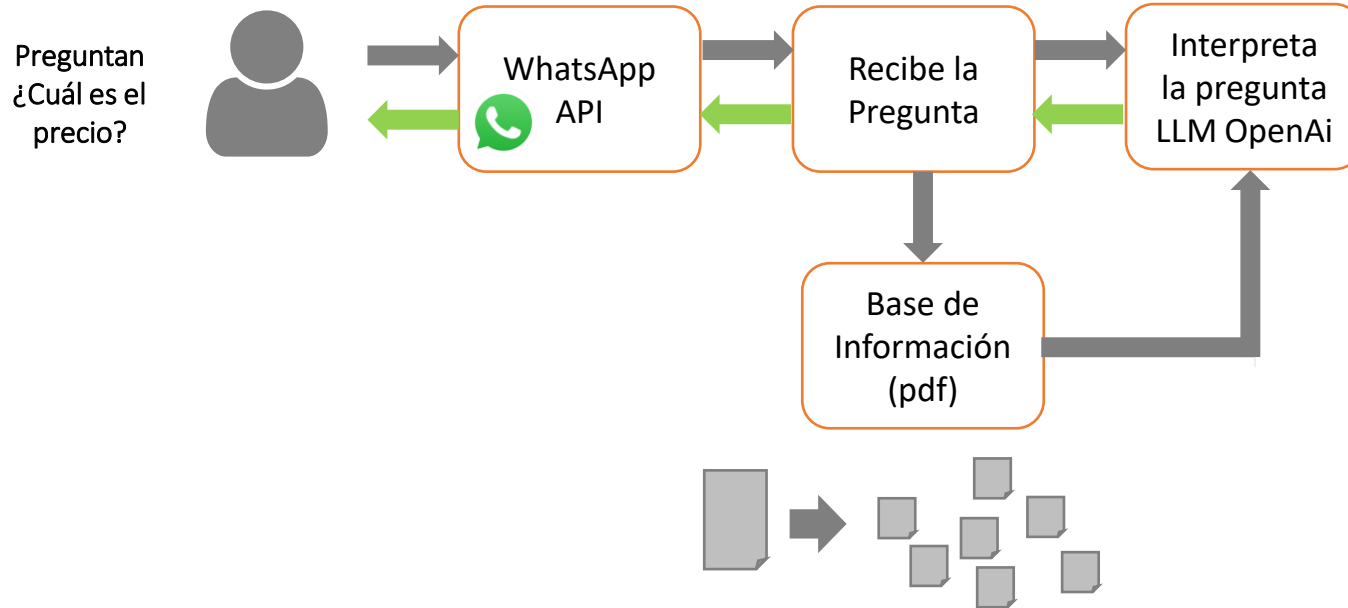
Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución



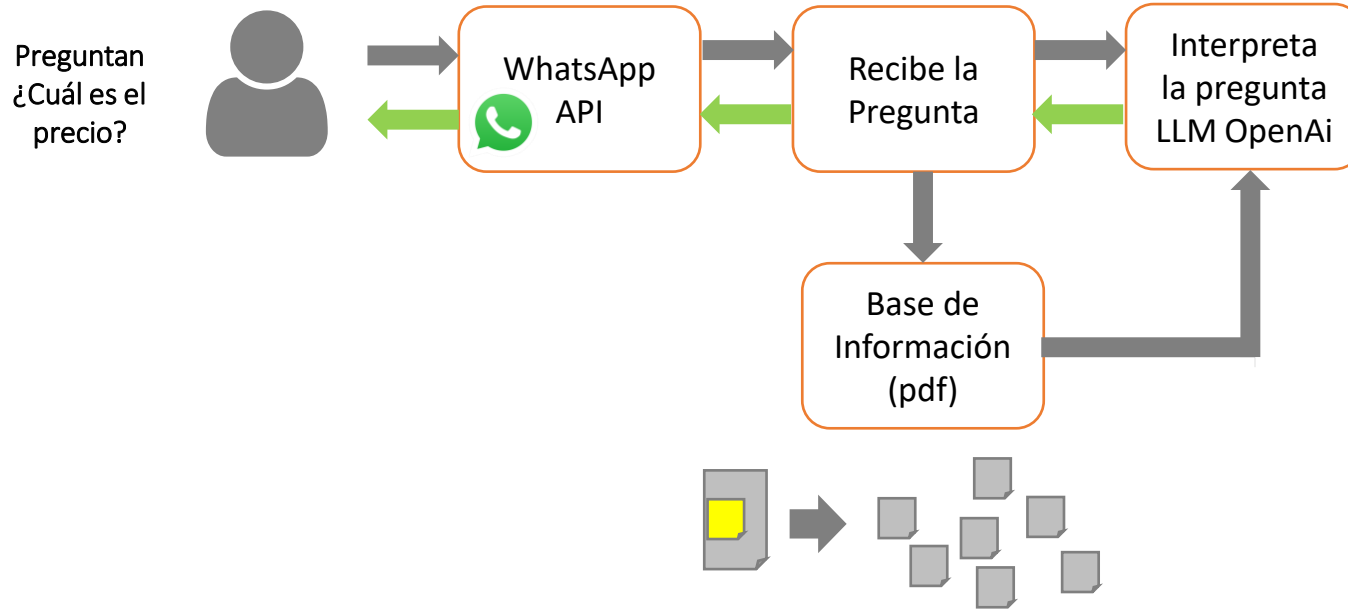
Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución



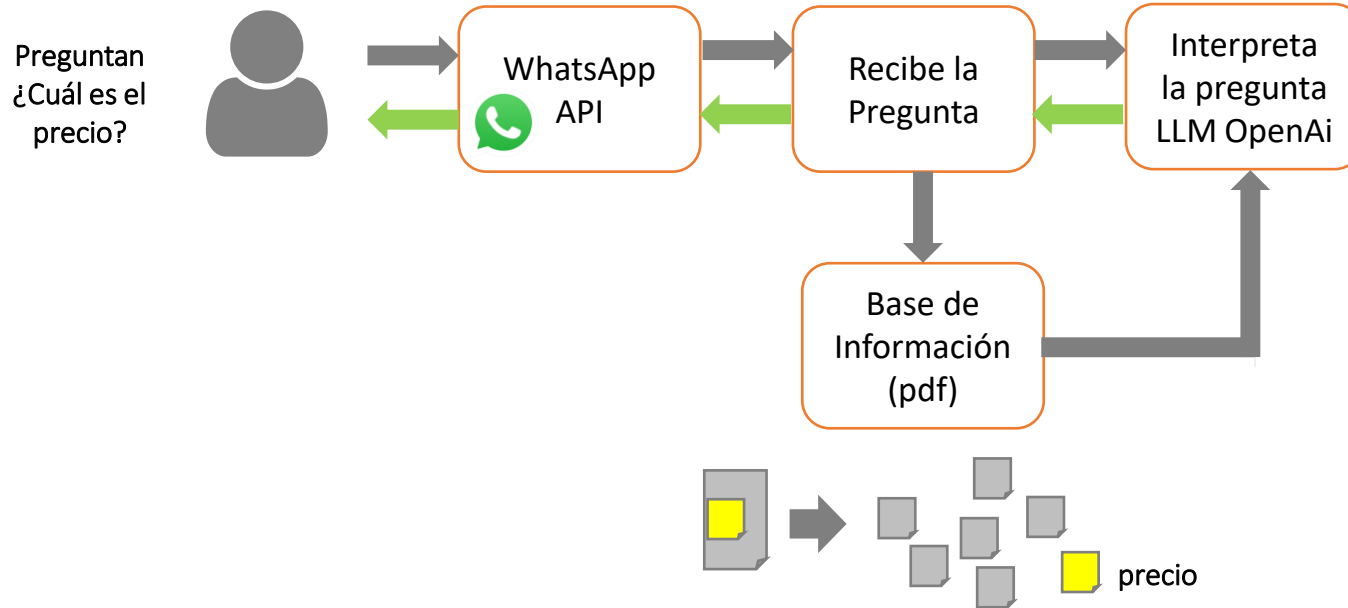
Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución




Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución



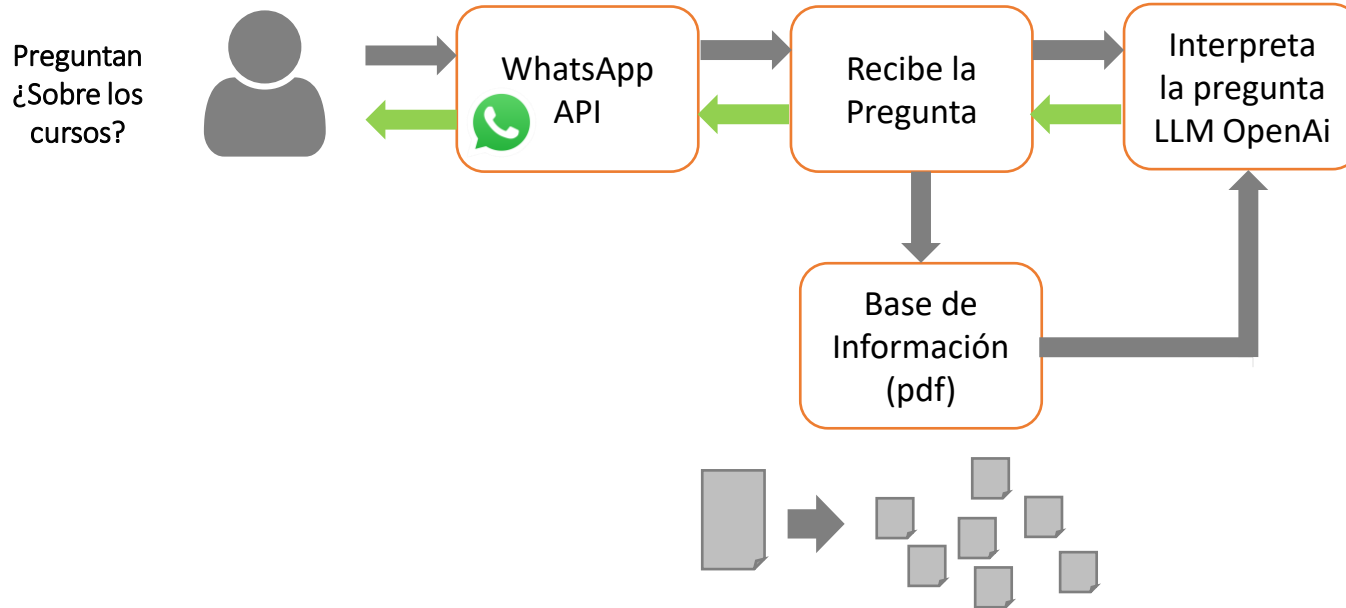
Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución



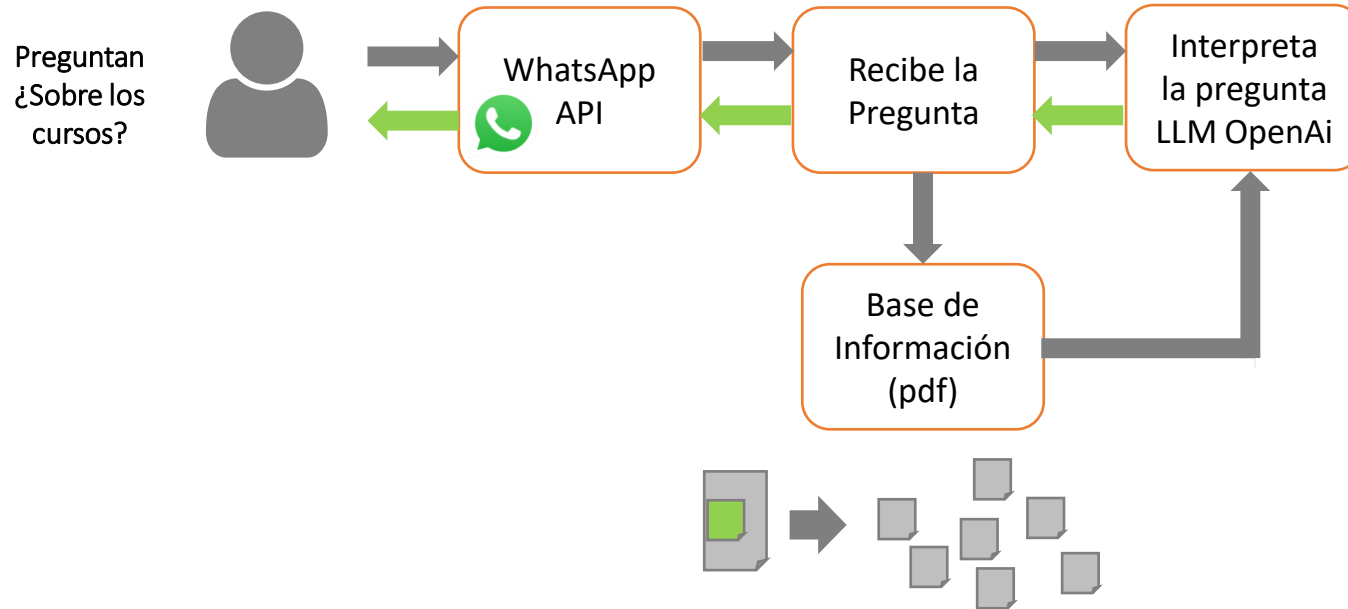
Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución



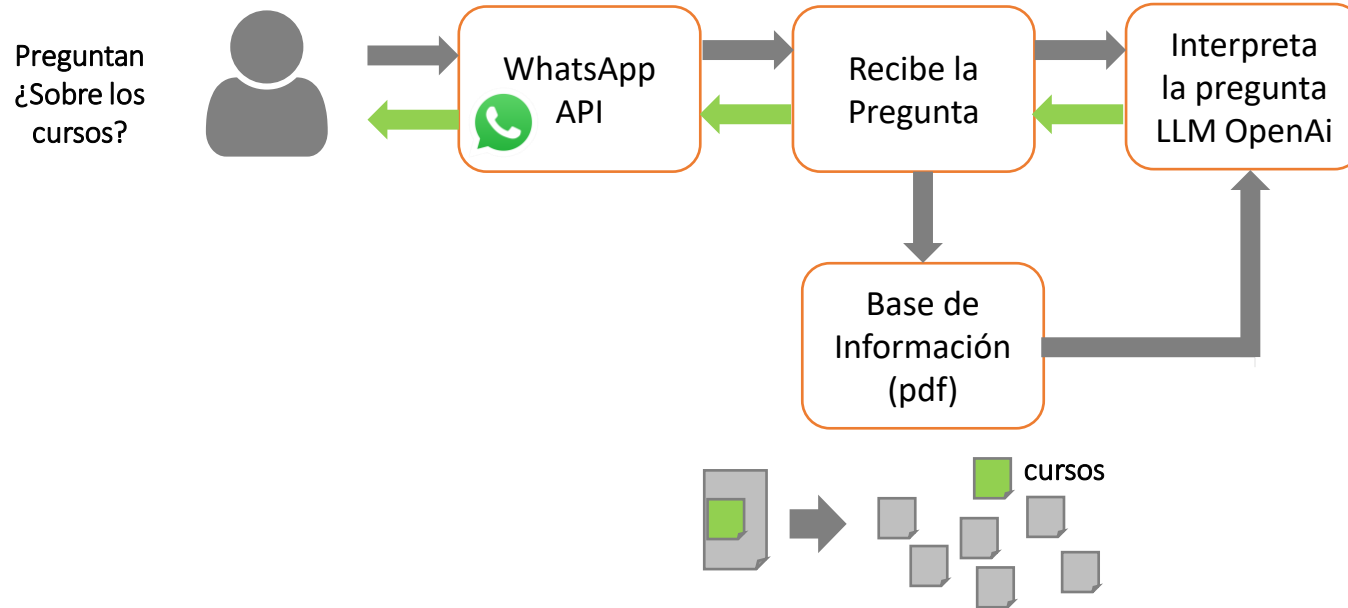
Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución




Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución




Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución




Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución




Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución




Chunk → Tokens → Embeddings → Similitud del coseno

CHUNK → TOKENS → EMBEDDINGS → SIMILTUD DEL COSENO




Convertir los texto grande en pequeños trozos de texto.




convertir los textos en tokens.

Probar: <https://platform.openai.com/tokenizer>




Convertir los textos en tokens y luego en vectores.




Los Algoritmos, **necesitan vectores.**

rey	1, 1
reina	1, 0.9
avión	-0.8, 0.5




Si los textos son vectores, entonces podemos crear algoritmos.


rey	1, 1
reina	1, 0.9
avión	-0.8, 0.5



Podemos medir que tanta **similitud** tienen.
Rey y Reina están cerca son similares, avión está lejos, no es similar.



Podemos medir que tanta *similitud* tienen.
Rey y Reina están cerca son similares, avión está lejos, no es similar.




Podemos medir que tanta *similitud* con el coseno del ángulo que forman los vectores.

¿Cuál es el precio?

El precio del programa es 4500 euros


El contenido del programa es ...



(Pregunta + chunk) → LLM


Ejemplo: Chatbot con IA

¿Qué problema observan? → Solución



LAB

TOKENIZACION → EMBEDDING → ALGORITMOS



Lenguaje de Programación

- Python

IDE

- Jupyter notebook

notebooks

- `tokens_embeddings.ipynb`

Configuración

```
PS C:\Users\Temporal\Documents\embeddings_demo> python -m venv .venv
```

```
PS C:\Users\Temporal\Documents\embeddings_demo>
```

```
PS C:\Users\Temporal\Documents\embeddings_demo> .\venv\Scripts\Activate.ps1
```


```
(.venv) PS C:\Users\Temporal\Documents\embeddings_demo> pip --versión
```

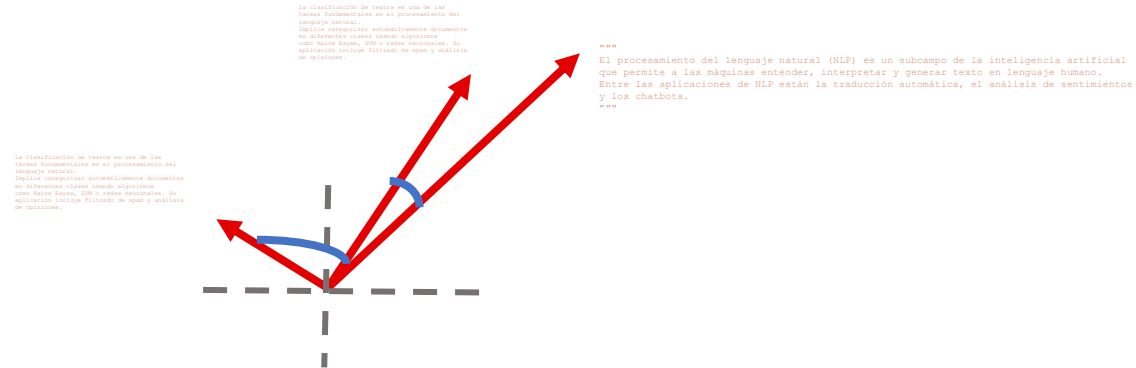
```
pip 25.1.1 from C:\Users\Temporal\Documents\embeddings_demo\.venv\Lib\site-packages\pip (python 3.13)
```

```
(.venv) PS C:\Users\Temporal\Documents\embeddings_demo> pip install -r requirements.txt
```

```
(.venv) PS C:\Users\Temporal\Documents\embeddings_demo> python -m spacy download en_core_web_sm
```

Bag Of Words







Podemos medir que tanta **similitud** con el coseno del ángulo que forman los vectores.

Resumen de la similitud del coseno

Caso: Plagio de Tesis



Se presume un plagio entre la tesis 1 y la tesis 3.